Rendu 1 : Rapport d'exploration, de data visualisation et de pré-traitement des données

Table des matières

1. Introduction 1
2. Objectif 2
3. Compréhension et manipulation des données 2
   3.1. Jeu de données utilisé 2
   3.2. Variable cible 3
4. Pré-processing et Feature Engineering 3
   4.1. Nettoyage des données 3
5. Analyses statistiques et visualisations 4
   5.1. Variables numériques 4
   5.2. Variables catégorielles 10
6. Conclusion 14

1. Introduction

a) Contexte métier

Dans le secteur de l'assurance, la fraude engendre des **pertes financières** importantes et mobilise des ressources humaines considérables pour le traitement des réclamations suspectes.

Dans ce contexte, le développement d'outils d'aide à la décision basés sur la data science permet d'optimiser la détection des fraudes et d'améliorer l'efficacité des processus internes.

b) Contexte technique

D'un point de vue technique, ce présent rapport consiste à appliquer des méthodes d'exploration de données, de visualisation, de pré-traitement et de sélection de variables afin de préparer les données à une future phase de modélisation supervisée.

c) Contexte économique

La détection précoce des réclamations frauduleuses permet de réduire les pertes financières, d'optimiser les ressources internes, et d'accélérer le traitement des dossiers légitimes.

L'enjeu économique est donc significatif.

d) Contexte scientifique

Scientifiquement, le projet s'inscrit dans un problème de **classification binaire supervisée**, avec pour objectif d'identifier les facteurs explicatifs associés à un comportement frauduleux.

2. Objectif

L'objectif principal est d'analyser un ensemble de données de réclamations d'assurance afin de développer un modèle prédictif capable de détecter les réclamations potentiellement frauduleuses.

a) Niveau d'expertise

Je suis débutante dans le domaine de l'assurance. Ce projet représente donc également une phase d'apprentissage métier pour ma part.

b) Interaction avec des experts

Nous n'avons pas été en contact avec des experts métier. L'interprétation repose donc uniquement sur l'analyse statistique et la cohérence logique des variables.

3. Compréhension et manipulation des données

3.1. Jeu de données utilisé

Le jeu de données utilisé est **insurance_claims.csv**, disponible librement via Mendeley Data.

Il contient :

- 1000 observations (réclamations)
- 39 variables explicative
- Une variable cible binaire : fraud_reported (oui / non)

Répartition :

- 75 % non fraude
- 25 % fraude

Il s'agit donc d'un **jeu de données déséquilibré.**

3.2. Variable cible

La variable à expliquer est fraud_reported, comportant deux modalités :

Oui (fraude)

Non (non fraude)

4. Pré-processing et Feature Engineering

4.1. Nettoyage des données

a) Gestion des valeurs manquantes

_c39 : colonne vide

authorities_contacted : 9 % de valeurs manquantes, les valeurs manquantes sont remplacées par une catégorie "Unknown" pour ne pas biaiser les résultats.

b) Suppression de variables non pertinentes

Avant de faire des tests statistiques sur la pertinence des variables, les variables 'policy_number (identifiant unique)' et '_c39' n'apporteraient pas d'information sur la variable cible selon la logique. Ainsi, nous avons décidé de les supprimer.

c) Transformation des dates

Les colonnes contenant des dates ont été converties au format *datetime*. Ensuite, la variable « **incident date** » a été transformée en une variable catégorielle distinguant deux modalités : « **week-end** » et « **semaine** ». L'objectif est d'identifier s'il existe une période plus propice à la fraude.

4.2. Rééquilibrage de certaines variables catégorielles

Afin d'éviter des catégories trop minoritaires, nous avons effectué le rééquilibrage suivant:

- *Incident type* : au lieu de 4 catégories déséquilibrées, une fusion a été effectué sur les 2 dernières catégories minoritaires. Au final, nous avons 3 catégories.

- *Incident state* : au lieu de 7 catégories mal reparties, nous avons regroupées les 3 catégories minoritaires en une seule. A la fin nous avons 4 catégories.

- *Incident severity* : fusion de "minor" et "trivial" qui sont deux catégories minoritaires

- *Capital gain / loss* : discrétisation en 3 catégories (0, 0 à 50k, et 50K à 100k)

- *Auto year* : regroupement en 3 catégories (very old, old, new)

4.3. Normalisation/standartisation

Les tests statistiques utilisés dans ce premier travail ne nécessitent ni normalisation ni standardisation. Celles-ci seront effectuées lors de la phase de modélisation.

5. Analyses statistiques et visualisations

Compte tenu des 39 variables explicatives, une étape de sélection a été réalisée. Elle s'est appuyée d'abord sur une analyse exploratoire à l'aide de graphiques, puis sur des tests statistiques afin d'identifier les variables les plus pertinentes.

Dan l'objectif de faciliter le traitement, nous avons séparé les variables en deux catégories selon leur nature : les variables numériques et les variables catégorielles.

5.1. Variables numériques

Pour avoir une vue d'ensemble sur la distribution des variables selon les catégories fraude et non fraude de la variable cible. La figure 1 suivante a été réalisée :

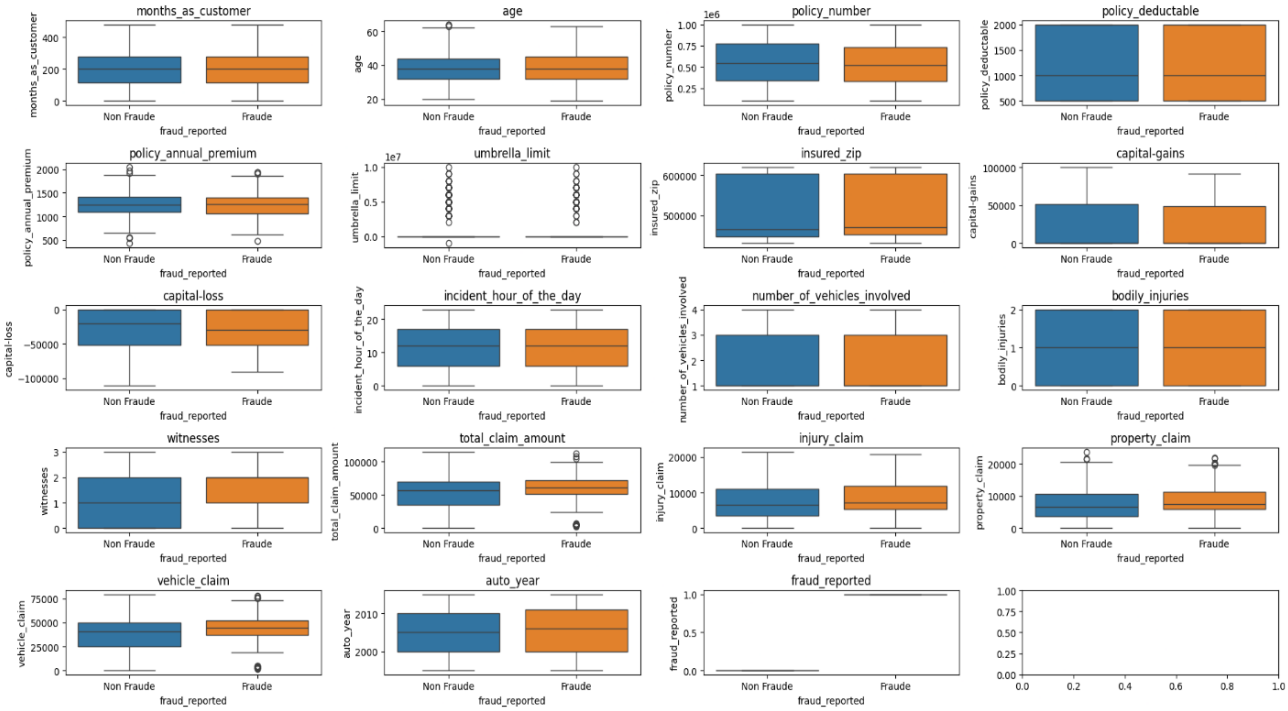

Figure 1: Diagramme en moustache des variables numériques selon la catégorie de la variable cible

Visuellement, d'après la figure 1, les variables présentant des distributions différentes entre fraude et non fraude, constitue une première piste pour évaluer la pertinence de chaque variable dans la détection des cas de non-fraude et de fraude, ces variables sont :

- policy number → numéro d'assurance
- capital loss → perte en capital
- witnesses → témoins
- total claim amount → montant total de la réclamation
- injury claim → réclamation pour dommages corporels
- property insurance_claims → réclamations d'assurance habitation / dommages matériels
- vehicle insurance_claims → réclamations d'assurance automobile
- auto year → année du véhicule

La question est désormais de déterminer si les différences observées visuellement entre les cas de fraude et de non-fraude sont statistiquement significatives. Autrement dit, nous cherchons à savoir si les deux groupes présentent des différences mesurables sur ces variables.

Pour cela, nous effectuerons des tests de comparaison entre deux groupes indépendants. Lorsque l'hypothèse de normalité est vérifiée, un test de Student sera utilisé. En revanche, si la distribution ne suit pas une loi normale, nous appliquerons le test non paramétrique de Mann–Whitney U.

a) Test de normalité

La première étape a consisté à vérifier si chaque variable suit une distribution normale. Pour cela, nous avons réalisé un test de Shapiro–Wilk.

- Si $p > 0{,}05$ → l'hypothèse de normalité n'est pas rejetée (pas de violation de la normalité).

- Si $p \leq 0{,}05$ → l'hypothèse de normalité est rejetée (distribution non normale).

Le test de normalité a montré que seule la variable **policy annual premium** suit une distribution normale. Par conséquent, le test t de Student peut être appliqué à cette variable.

La figure 2 ci-dessous permet de confirmer visuellement cela.

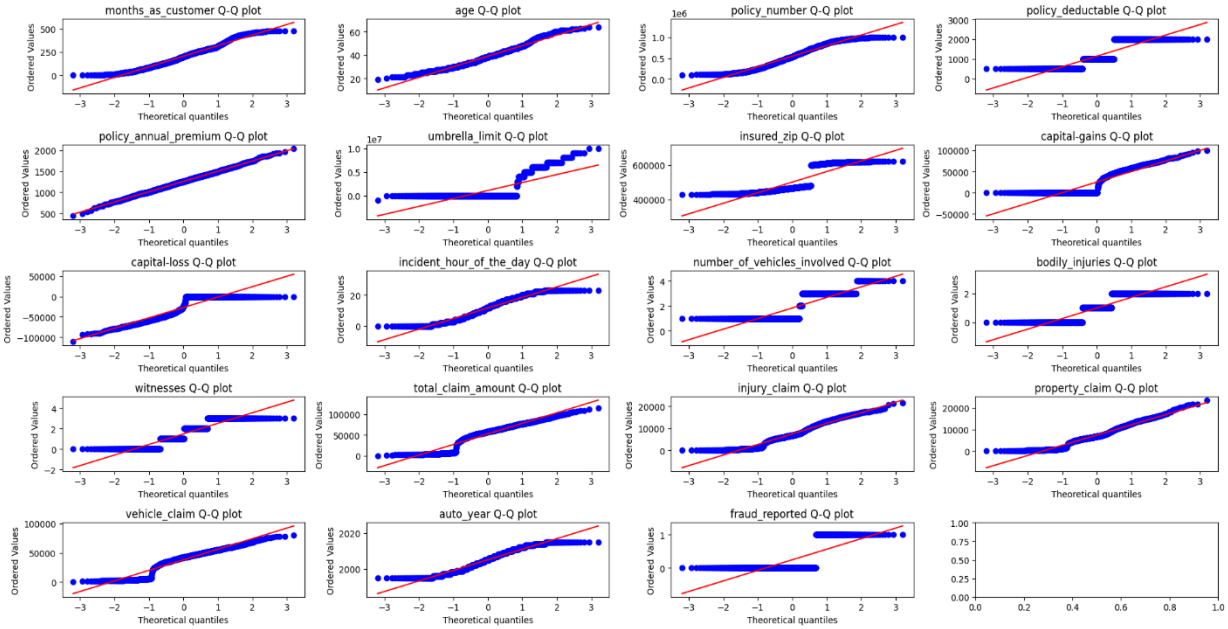

*Figure 2: Diagramme QQ-plot, la ligne rouge représente la distribution théorique attendue sous l'hypothèse de normalité, tandis que les points bleus correspondent aux quantiles observés de la variable. Plus les points sont alignés sur la ligne rouge, plus la distribution empirique est proche d'une loi normale. On observe que seule la variable **policy annual premium** présente un alignement satisfaisant le long de cette droite, ce qui confirme qu'elle est la seule à suivre approximativement une distribution normale*

b) Test T de student

Comme policy annual suit une distribution normale, on applique un test T de student.

Le résultat a montré un p_value > 0.05, on conclue qu'il n'y a pas de différence significative entre les deux catégories fraude et non fraude.

c) Test de Mann-Whitney U

Pour les variables qui ne suivent pas la loi normale, le test de Mann-Whithey U a été appliqué.

Le test a permis de montrer que les variables suivantes présentent des *p-values* très faibles :

- **total_claim_amount**
- **injury_claim**
- **property_claim**
- **vehicle_claim**

Les *p-values*, inférieures au seuil de significativité (α = 0,05), indiquent qu'il existe une différence statistiquement significative entre les groupes fraude et non-fraude. **Ces variables peuvent donc être considérées comme pertinentes pour la construction du modèle.**

d) Information mutuelle

Précédemment, nous avons analysé si la distribution des variables différait entre les cas de fraude et de non-fraude.

Pour évaluer l'existence de liens entre la variable cible et les variables explicatives, nous avons calculé le **score d'information mutuelle**. Ce score permet de mesurer la relation (linéaire ou non) entre chaque variables explicatives et variable cible.

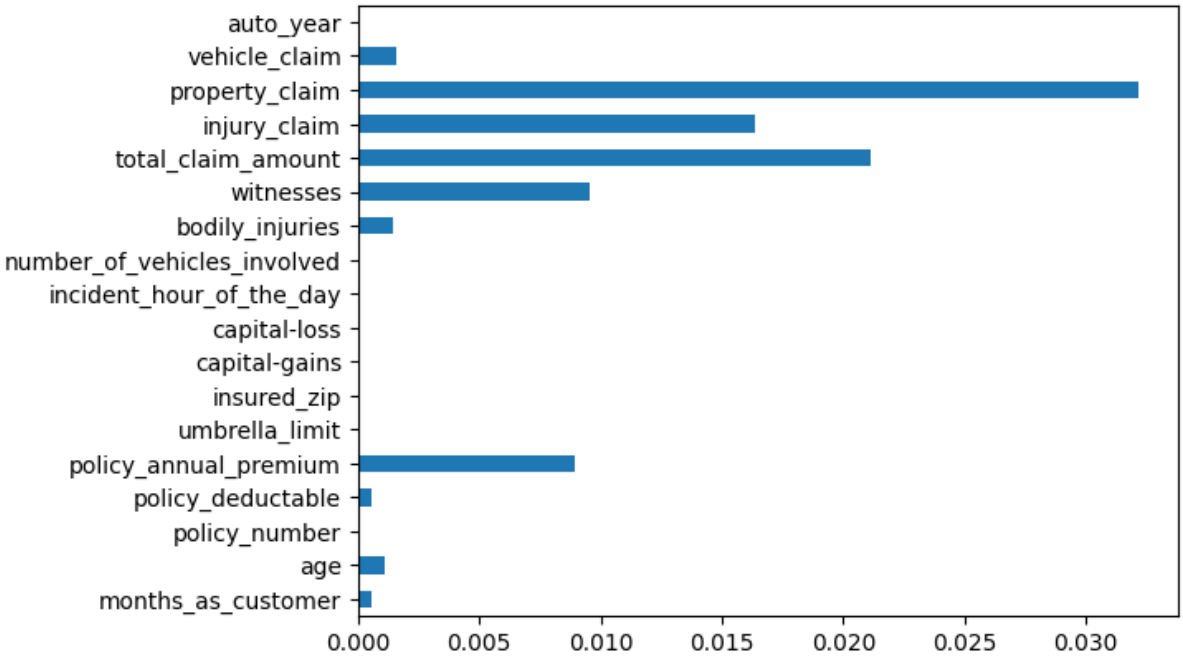

Figure 3: Information mutuelle entre variables numériques et la variable cible

La figure 3 nous montre les variables apportant le plus d'information pour la variable cible, qui sont :

- **property_claim**
- **total_claim_amount**
- **injury_claim**
- **witnesses**
- **policy annual premium**
- **bodily_injuries**
- **vehicle_claim**
- **age**

e) Correlation entre variable

L'étape suivante consiste à identifier les variables apportant des informations redondantes. Pour cela, nous avons calculé la corrélation entre les variables, montré par la figure de matrice de corrélation suivante :

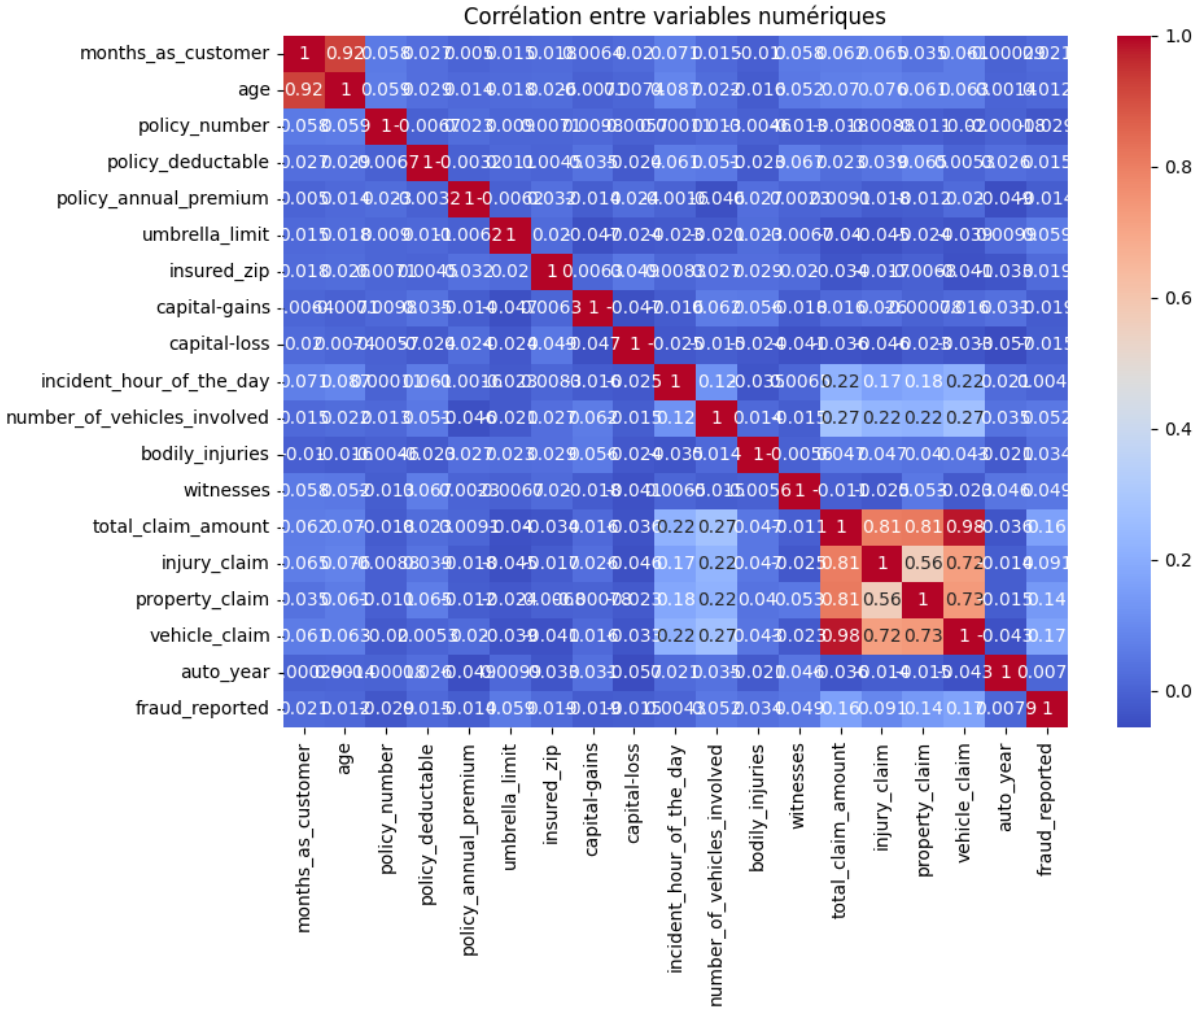

Figure 4: Matrice de correlation entre variables numériques

D'après la figure 4, on observe que **injury_claim**, **property_claim** et **vehicle_claim** sont fortement corrélées avec **total_claim_amount** (corrélation > 0,8). Ces variables étaient déjà jugées pertinentes pour distinguer fraude et non-fraude lors des tests précédents.

Afin de réduire la dimensionnalité du jeu de données tout en conservant l'information, nous avons décidé de ne conserver que **total_claim_amount**.

f) Test de la Forward Sequential Selection :

En plus des différents tests précédemment, nous avons calculé la Forward Sequential Selection. Il s'agit d'une méthode itérative qui commence avec un modèle vide et ajoute progressivement les variables (*features*) ayant le plus d'impact positif sur la performance du modèle, jusqu'à ce qu'un critère d'arrêt soit atteint.

Avec le paramètre KNN=5 voisins, les variables retenues comme les plus pertinentes sont:

- **policy_annual_premium**

- **incident_hour_of_the_day**

- **number_of_vehicles_involved**

- **bodily_injuries**

- **total_claim_amount**

5.2. Variables catégorielles

Pour explorer les variables catégorielles, nous avons réalisé la figure ci-dessous, qui permet de visualiser la répartition des cas de fraude et de non-fraude.

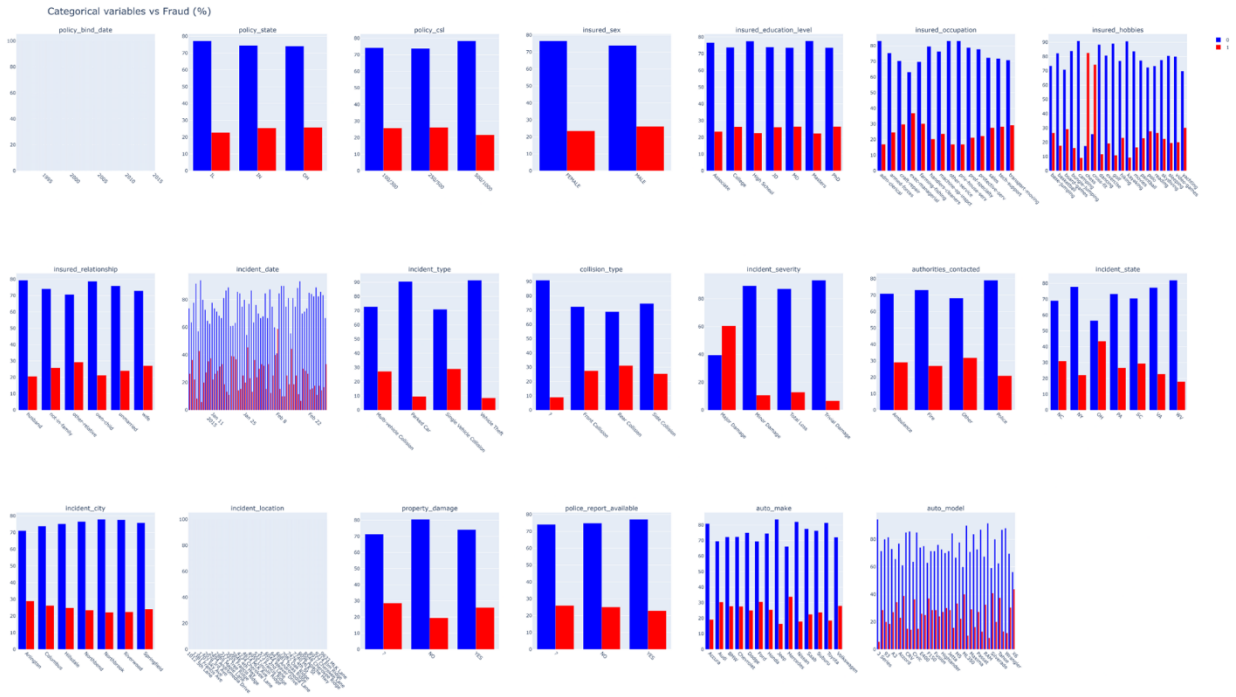

Figure 5: Vue d'ensemble des variables catégorielles selon les catégories de la variable cible (non fraude et fraude)

D'après la figure 5, certaines variables catégorielles présentent des distributions très différentes entre les cas de fraude et de non-fraude :

- **Insured occupation** : beaucoup de fraudes pour la catégorie *manager/executive*, correspondant à des personnes occupant des postes clés, potentiellement plus conscientes des failles du système d'assurance.

- **Insured hobbies** : les assurés jouant aux échecs présentent un nombre élevé de fraudes.

- **Incident date** : le mois de février montre une proportion plus élevée de fraudes.

- **Incident type** : les incidents impliquant des collisions présentent un risque de fraude élevé.

- **Collision type** : *Rear* et *Front* sont les types de collision les plus associés à des cas de fraude.

- **Incident severity** : la catégorie *major damage* est fortement liée à la fraude.

- **Incident state** : l'État de Chicago présente un nombre important de fraudes.

- **Property damage**

- **Auto make** : les véhicules Mercedes, Ford, Audi et Volkswagen sont plus fréquemment impliqués dans des cas de fraude.

- **Auto model** : les modèles X6 (BMW), Silverado (Chevrolet), ML350 et C300 (Mercedes) apparaissent souvent dans les dossiers de fraude.

a) Information mutuelle

Les variables présentant un lien significatif avec la variable cible, selon la figure 6, sont :

- **Incident severity**

- **Insured hobbies**

- **Auto model**

- **Incident state**

- **Policy CSL**

- **Incident type**

- **Policy state**

- **Authorities contacted**

- **Property damage**

- **Collision type**

- **Incident city**

Ces variables correspondent également à celles dont les distributions diffèrent visiblement entre fraude et non-fraude, comme montré précédemment. Elles constituent donc des variables pertinentes pour notre modèle.

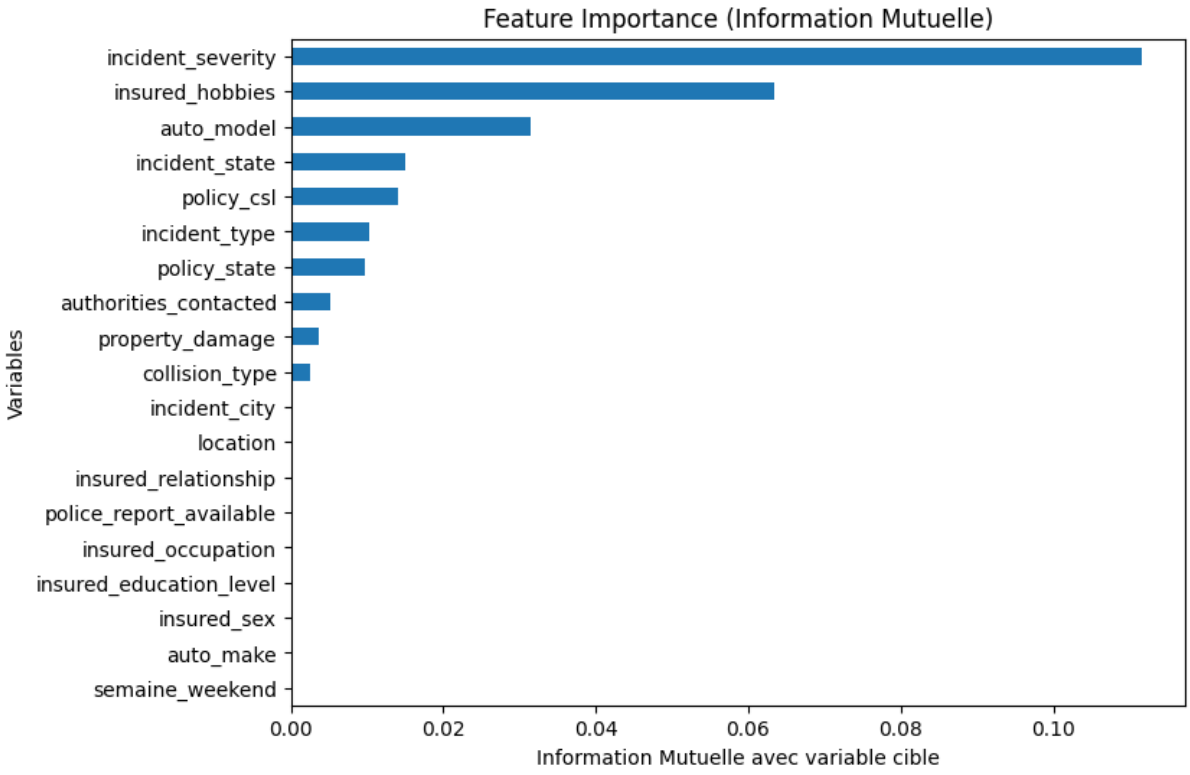

Figure 6: Information mutuelle - variables catégorielles

b) Test Vcramer

Pour évaluer la force de l'association entre deux variables catégorielles, nous avons utilisé la méthode de V Cramer. La valeur de V Cramer varie entre 0 et 1 : plus la valeur est proche de 1, plus l'association entre les variables est forte, indiquant que la variable explicative est pertinente pour expliquer la variable cible. À l'inverse, une valeur proche de 0 suggère qu'il n'existe pas de lien significatif entre les variables.

Selon le score de VCramer, les variables les plus pertinentes pour expliquer la variable cible sont :

- **incident_severity** : 0,5134
- **insured_hobbies** : 0,4029
- **auto_model** : 0,216
- **collision_type** : 0,1771

- **incident_type** : 0,1706
- **authorities_contacted** : 0,1622
- **insured_occupation** : 0,1329
- **auto_make** : 0,1174
- **incident_state** : 0,1049
- **property_damage** : 0,0896
- **insured_relationship** : 0,0734
- **location** : 0,064
- **incident_city** : 0,0511
- **policy_csl** : 0,0462
- **insured_education_level** : 0,0411
- **policy_state** : 0,032
- **police_report_available** : 0,029
- **insured_sex** : 0,0285

c) Test de Khi-2

Le test du chi-deux est une méthode statistique classique utilisée pour évaluer l'existence d'une relation entre deux variables catégorielles. Il permet de comparer les fréquences observées dans un tableau de contingence avec les fréquences attendues si les variables étaient indépendantes.

Tableau 1 : Liste des variables les plus pertinentes selon le test de Khi-2 :

Variable	Variable cible	p-value	Interprétation
incident_severity	fraud_reported	5,76e-58	Très fortement associée à la fraude
insured_hobbies	fraud_reported	8,99e-25	Forte association

incident_type	fraud_reported	4,78e-07	Association significative
collision_type	fraud_reported	7,12e-07	Association significative
authorities_contacted	fraud_reported	2,73e-05	Association significative
incident_state	fraud_reported	1,17e-02	Association modérée
property_damage	fraud_reported	1,80e-02	Association modérée
umbrella_limit_cut	fraud_reported	7,94e-02	Association faible/non significative

6. Conclusion

L'analyse confirme qu'il s'agit d'un **problème de classification binaire**.

À partir des différentes étapes d'exploration des données qu'on a vu précédemment, le tableau ci-dessous récapitule **les variables les plus pertinentes à prendre en compte pour la construction de notre modèle.**

Bien que les différents tests n'aient pas toujours donné les mêmes résultats, nous avons conservé uniquement les variables qui se sont révélées significatives selon le/les tests appliqués.

Tableau 2: Tableau recapitulatif des résultats

Variables	**Tests réalisés et résultats significatifs**	**à garder ?**	**Commentaire**
Total claim amount	1-Information mutuelle, 2-Forward sequential selection, 3-Mannwitneyu	oui	Donne la même information que : injury claim, property claim, vehicle claim

policy annual premium	1-Information mutuelle, 2-Forward Sequential Selection	oui	
incident hour of the day	1-Forward sequen	oui	Variable restrucurée
number of vehicle involved	1-Forward sequen	oui	
witnesses	1-Information mutuelle	oui	
bodily injuries	1-Information mutuelle, 2-Forward sequential selection	oui	
insured occupation	1- Vcramer 2- Chi2 3- info mutuelle	oui	
insured hobbies	1-Vcramer 2- Chi2 3- info mutuelle	oui	
incident type	1-Vcramer,	oui	

	2-Chi2, 3-info mutuelle		
collision type	1-Vcramer, 2-Chi2, 3- info mutuelle	oui	
incident severity	1-Vcramer 2-Chi2	oui	
authorities contaced	1-Vcramer, 2-Chi2		
Incident state	1-Vcramer 2-Chi2, 3-info mutuelle	oui	
Property damage	1 - info mutuelle	A discuter	
Auto make	1-Vcramer, 2-Chi2	non	Correlé avec auto model, à supprimer
auto model	1-Vcramer,2-Chi2	oui	Correlé avec auto model, à garder